

وثيقة عربية تجريبية لاختبار الاسترجاع متعدد الوسائط

ملف اختبار اصطناعي - للاستخدام في POC الخاص بـ RAG-Anything

1. مقدمة

تهدف هذه الوثيقة إلى اختبار قدرة النظام على فهرسة النص العربي واسترجاع المعلومات باستخدام أسئلة مكتوبة باللغة العربية. يحتوي الملف على فقرات واضحة، أسماء أماكن، تواريخ، وجدول بسيط.

العبارة المستهدفة الأولى: الأرشفة الرقمي يساعد الباحثين على الوصول إلى المصادر بسرعة ودقة.

2. موضوع تجريبي

بدأ مشروع رقمنة مجموعة تاريخية في عام 2024، وكان الهدف منه تنظيم الكتب والصور والتسجيلات الصوتية والفيديوهات في مستودع واحد. ركز الفريق على الحفاظ على المصدر الأصلي وربط كل نتيجة باسم الملف ورقم الصفحة أو الطابع الزمني.

ناقش الفريق أيضاً أهمية اللغة العربية، لأن اختلاف أشكال الحروف والتشكيل وجودة المسح الضوئي قد يؤثر في نتائج البحث. لذلك تم اقتراح مقارنة أكثر من محرك OCR قبل اعتماد المكوّن النهائي.

3. معلومات قابلة للبحث

العنصر	القيمة
اسم المشروع	مشروع الذاكرة الرقمية
سنة البداية	2024
المدينة التجريبية	لاهور
الأولوية	دقة المصدر والاستشهاد

أسئلة مقترحة: ما اسم المشروع؟ ما سنة البداية؟ ما الأولوية الرئيسية؟

العلاقات والسياق التاريخي

4. مثال على العلاقات

يحتوي الأرشيف التجريبي على مواد مرتبطة بعدة مدن ومؤسسات. تشير إحدى الملاحظات إلى أن باحثاً زار دمشق ثم انتقل إلى بغداد لدراسة مجموعة من الوثائق، وبعد ذلك قارن النتائج بنسخ محفوظة في إسطنبول.

العبارة المستهدفة الثانية: انتقل الباحث من دمشق إلى بغداد قبل مقارنة المخطوطات بنسخ محفوظة في إسطنبول.

هذا النوع من المعلومات مناسب لاختبار الاسترجاع القائم على العلاقات، لأن السؤال قد لا يستخدم الكلمات نفسها الموجودة في النص، بل يسأل عن تسلسل الأماكن أو العلاقة بين الشخص والحدث والمصدر.

5. أسئلة لاختبار RAG

يمكن سؤال النظام: إلى أي مدينة انتقل الباحث بعد دمشق؟ أين وُجدت النسخ التي استُخدمت للمقارنة؟ ولماذا تعد دقة الاستشهاد مهمة في نظام الأرشيف؟

الإجابة الصحيحة يجب أن تعتمد على النص المسترجع، وأن تشير إلى الصفحة الأصلية بدلاً من إنشاء معلومات غير موجودة في المصدر.

هذه المادة مصطنعة بالكامل لأغراض الاختبار.

صفحة أرشيفية ممسوحة ضوئياً

تتناول هذه الصفحة نموذجاً تجريبياً لاختبار دقة التعرف
الحروف العربية في الوثائق الممسوحة ضوئياً.

يشمل الاختبار أسماء الأماكن والتواريخ والمصطلحات
المدينة المنورة، دمشق، بغداد، القرن التاسع الهجري، و
التاريخية.

العبارة المستهدفة للبحث: حفظ التراث الرقمي وإتاحته
للباحثين.